Nama : Az – Zahra Chikal E

NIM : 1103213039

Kelas : TK-45-05

TUGAS WEEK 14 Bidirectional RNN

```
import torch
import torch.nn as nn
import torch.optim as optim
from torch.utils.data import DataLoader, Dataset
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
import numpy as np
import pandas as pd
from tqdm import tqdm    Import "tqdm" could not be resolved from source
import matplotlib.pyplot as plt
import seaborn as sns
```

✓ 1.3s Python

```
# Load and preprocess data
data = pd.read_csv('bank-full.csv', delimiter=';')
data.head()
```

✓ 0.0s Python

Output:

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
0	58	management	married	tertiary	no	2143	yes	no	unknown	5	may	261	1	-1	0	unknown	no
1	44	technician	single	secondary	no	29	yes	no	unknown	5	may	151	1	-1	0	unknown	no
2	33	entrepreneur	married	secondary	no	2	yes	yes	unknown	5	may	76	1	-1	0	unknown	no
3	47	blue-collar	married	unknown	no	1506	yes	no	unknown	5	may	92	1	-1	0	unknown	no
4	33	unknown	single	unknown	no	1	no	no	unknown	5	may	198	1	-1	0	unknown	no

Analisis:

Kode diatas digunakan untuk membuat model machine learning menggunakan PyTorch. Data yang digunakan yaitu bernama `bank-full.csv`, yang berisi informasi tentang pelanggan bank. Data ini dimuat ke dalam program menggunakan Pandas dengan pemisah `;` karena format filenya menggunakan titik koma untuk memisahkan kolom. Untuk memahami isi dan struktur data, ditampilkan beberapa baris pertama dengan `data.head()`. Selanjutnya, data ini akan diproses dan dianalisis menggunakan alat bantu seperti NumPy, Scikit-learn, serta divisualisasikan menggunakan Matplotlib dan Seaborn sebelum digunakan untuk melatih model.

```
data.info()
```

✓ 0.0s Python

```
data.describe()
```

✓ 0.0s Python

Output:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 45211 entries, 0 to 45210
Data columns (total 17 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   age        45211 non-null  int64
 1   job        45211 non-null  object
 2   marital    45211 non-null  object
 3   education  45211 non-null  object
 4   default    45211 non-null  object
 5   balance    45211 non-null  int64
 6   housing    45211 non-null  object
 7   loan       45211 non-null  object
 8   contact    45211 non-null  object
 9   day        45211 non-null  int64
 10  month      45211 non-null  object
 11  duration   45211 non-null  int64
 12  campaign   45211 non-null  int64
 13  pdays      45211 non-null  int64
 14  previous   45211 non-null  int64
 15  poutcome   45211 non-null  object
 16  y          45211 non-null  object
dtypes: int64(7), object(10)
memory usage: 5.9+ MB
```

	age	balance	day	duration	campaign	pdays	previous
count	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000
mean	40.936210	1362.272058	15.806419	258.163080	2.763841	40.197828	0.580323
std	10.618762	3044.765829	8.322476	257.527812	3.098021	100.128746	2.303441
min	18.000000	-8019.000000	1.000000	0.000000	1.000000	-1.000000	0.000000
25%	33.000000	72.000000	8.000000	103.000000	1.000000	-1.000000	0.000000
50%	39.000000	448.000000	16.000000	180.000000	2.000000	-1.000000	0.000000
75%	48.000000	1428.000000	21.000000	319.000000	3.000000	-1.000000	0.000000
max	95.000000	102127.000000	31.000000	4918.000000	63.000000	871.000000	275.000000

Analisis:

Kode tersebut digunakan untuk mengetahui informasi terkait dataet. Dari code tersebut dapat kita tahui bahwa terdapat 16 kolom dengan jumlah data yaitu 45211. untuk datatype terdapat 2 yaitu int dan object. Fungsi `df.describe()` digunakan untuk memberikan ringkasan statistik dasar dari data numerik dalam sebuah DataFrame. Hasilnya mencakup informasi seperti jumlah data (count), rata-rata (mean), standar deviasi (std), nilai minimum (min), kuartil (25%, 50%, 75%), dan nilai maksimum (max) untuk setiap kolom numerik. Dengan menggunakan fungsi ini, kita dapat dengan cepat memahami karakteristik umum data, seperti distribusi nilai, rentang data, dan keberadaan kemungkinan nilai ekstrem.

```python
print("\nTarget Variable Distribution:")
sns.countplot(x='y', data=data)
plt.title('Target Variable Distribution')
plt.show()
```

✓ 0.1s Python

```python
print("\nCorrelation Heatmap:")
corr = data.select_dtypes(include=['float64', 'int64']).corr()
sns.heatmap(corr, annot=True, fmt='.2f', cmap='coolwarm')
plt.title('Correlation Heatmap')
plt.show()
```

✓ 0.1s Python

Output:

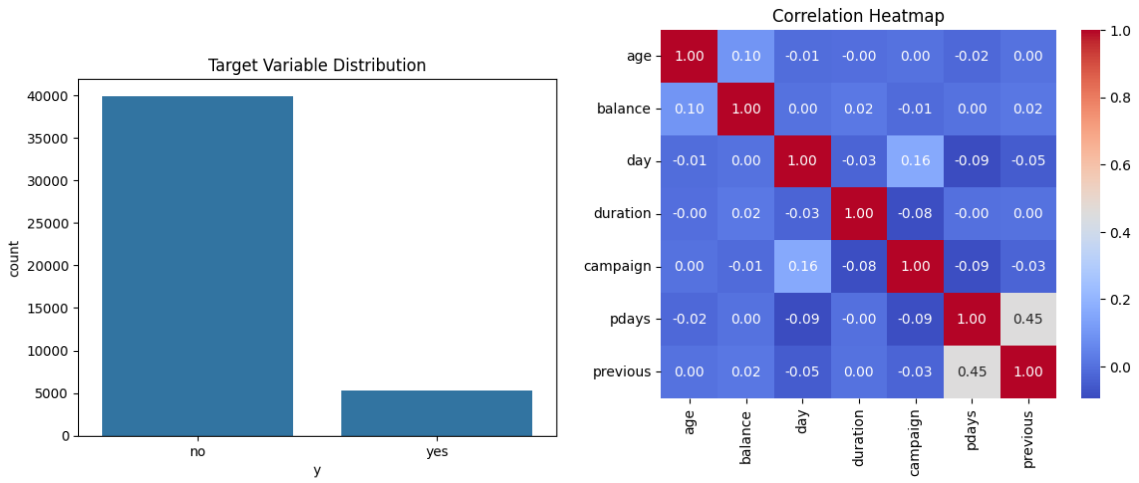

Analisis:

Kode ini digunakan untuk memahami data dengan lebih mudah melalui grafik. Pertama, grafik batang dibuat untuk melihat distribusi nilai pada variabel target y, sehingga kita bisa mengetahui seberapa banyak setiap kategori muncul dalam data. Setelah itu, hubungan antara fitur numerik dalam dataset dihitung menggunakan korelasi, yang menunjukkan seberapa kuat dan arah hubungan antara dua variabel. Hasilnya ditampilkan dalam bentuk heatmap yang mempermudah kita melihat pola hubungan ini. Kedua langkah ini membantu kita memahami data sebelum melanjutkan ke analisis atau pemodelan lebih lanjut.

```python
# preprocessing
X = data.drop('y', axis=1)
X = pd.get_dummies(X)
y = data['y'].apply(lambda x: 1 if x == 'yes' else 0)

scaler = StandardScaler()
X = scaler.fit_transform(X)

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Create Dataset class
class CustomDataset(Dataset):
    def __init__(self, X, y):
        self.X = torch.tensor(X, dtype=torch.float32)
        self.y = torch.tensor(y.values, dtype=torch.float32)

    def __len__(self):
        return len(self.y)

    def __getitem__(self, idx):
        return self.X[idx], self.y[idx]

train_dataset = CustomDataset(X_train, y_train)
test_dataset = CustomDataset(X_test, y_test)

train_loader = DataLoader(train_dataset, batch_size=64, shuffle=True)
test_loader = DataLoader(test_dataset, batch_size=64, shuffle=False)
```

✓ 0.1s Python

Analisis:

Kode tersebut digunakan untuk memproses data dalam model machine learning berbasis PyTorch. Dataset dipisahkan menjadi fitur (X) dan target (y), di mana y diubah menjadi nilai numerik (1 untuk yes dan 0 untuk no). Fitur yang mengandung data kategorikal diubah menjadi bentuk numerik menggunakan one-hot encoding, lalu distandarisasi dengan StandardScaler untuk memastikan setiap fitur memiliki skala yang seragam. Data dibagi menjadi set pelatihan dan pengujian menggunakan rasio 80:20. Selanjutnya, kelas CustomDataset dibuat untuk mengelola data dalam format yang kompatibel dengan

PyTorch, mengubah data menjadi tensor, dan menyediakan metode untuk mengakses data berdasarkan indeks. Untuk efisiensi pelatihan, DataLoader digunakan untuk membuat batch data dengan ukuran 64, di mana data pelatihan diacak untuk meningkatkan generalisasi model. Proses ini memastikan data siap digunakan dalam pelatihan neural network.

```python
# Define Bidirectional RNN model
class BiRNN(nn.Module):
    def __init__(self, input_size, hidden_size, num_layers, output_size, pooling='max'):
        super(BiRNN, self).__init__()
        self.rnn = nn.RNN(input_size, hidden_size, num_layers, batch_first=True, bidirectional=True)
        self.pooling = pooling
        self.fc = nn.Linear(hidden_size * 2, output_size)

    def forward(self, x):
        out, _ = self.rnn(x)
        if self.pooling == 'max':
            out = torch.max(out, dim=1).values
        elif self.pooling == 'avg':
            out = torch.mean(out, dim=1)
        out = self.fc(out)
        return out
```

✓ 0.0s Python

Analisis:

Kode tersebut mendefinisikan sebuah model *Bidirectional Recurrent Neural Network* (BiRNN) menggunakan PyTorch, yang dirancang untuk menangani data berbasis urutan, seperti teks atau data waktu. Model ini menggunakan arsitektur RNN bidirectional, memungkinkan jaringan mempelajari informasi dari urutan data maju dan mundur sekaligus, sehingga menghasilkan pemahaman konteks yang lebih baik. Input data pertama-tama diproses melalui lapisan RNN untuk menghasilkan output dari semua langkah waktu. Kemudian, output ini diringkas menggunakan salah satu metode pooling: *max pooling* untuk mengambil nilai maksimum, atau *average pooling* untuk menghitung rata-rata di sepanjang dimensi waktu. Setelah itu, hasil pooling diteruskan ke lapisan fully connected untuk menghasilkan prediksi akhir. Model ini dirancang fleksibel, dengan parameter yang dapat disesuaikan seperti ukuran input, jumlah unit tersembunyi, jumlah lapisan, dan metode pooling.

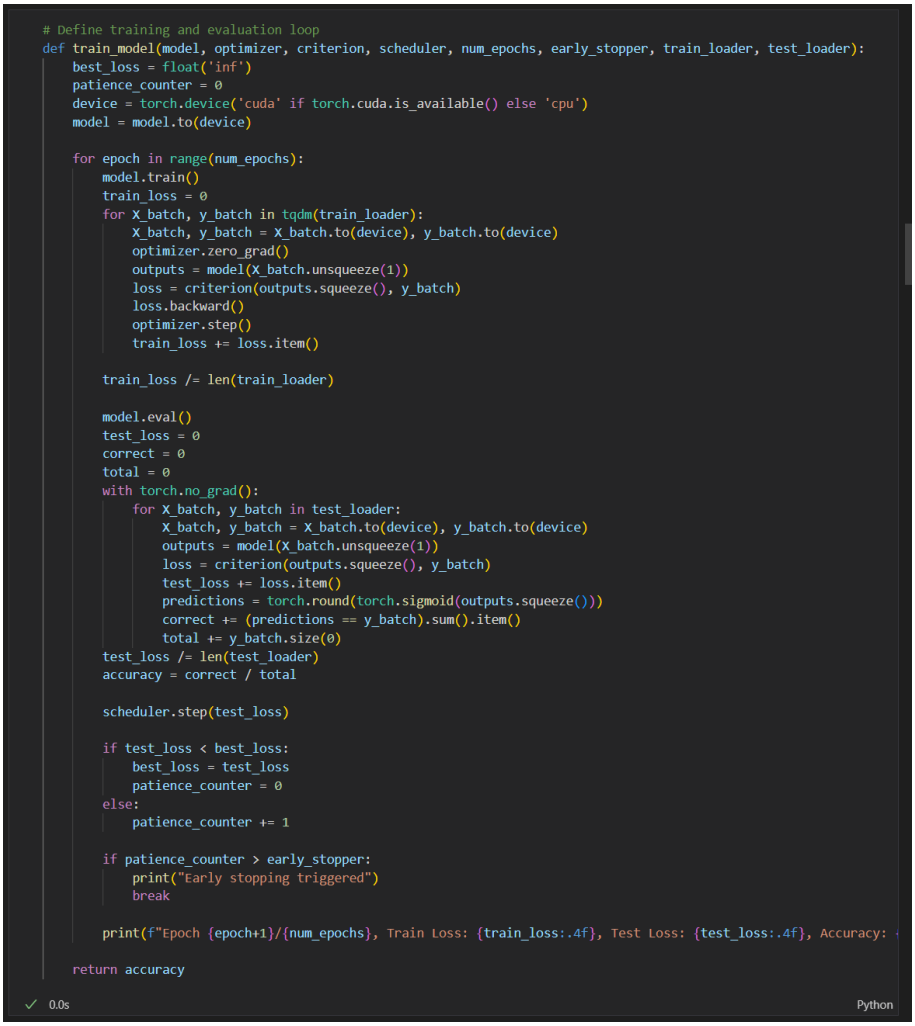

```python
# Define training and evaluation loop
def train_model(model, optimizer, criterion, scheduler, num_epochs, early_stopper, train_loader, test_loader):
    best_loss = float('inf')
    patience_counter = 0
    device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
    model = model.to(device)

    for epoch in range(num_epochs):
        model.train()
        train_loss = 0
        for X_batch, y_batch in tqdm(train_loader):
            X_batch, y_batch = X_batch.to(device), y_batch.to(device)
            optimizer.zero_grad()
            outputs = model(X_batch.unsqueeze(1))
            loss = criterion(outputs.squeeze(), y_batch)
            loss.backward()
            optimizer.step()
            train_loss += loss.item()

        train_loss /= len(train_loader)

        model.eval()
        test_loss = 0
        correct = 0
        total = 0
        with torch.no_grad():
            for X_batch, y_batch in test_loader:
                X_batch, y_batch = X_batch.to(device), y_batch.to(device)
                outputs = model(X_batch.unsqueeze(1))
                loss = criterion(outputs.squeeze(), y_batch)
                test_loss += loss.item()
                predictions = torch.round(torch.sigmoid(outputs.squeeze()))
                correct += (predictions == y_batch).sum().item()
                total += y_batch.size(0)
        test_loss /= len(test_loader)
        accuracy = correct / total

        scheduler.step(test_loss)

        if test_loss < best_loss:
            best_loss = test_loss
            patience_counter = 0
        else:
            patience_counter += 1

        if patience_counter > early_stopper:
            print("Early stopping triggered")
            break

        print(f"Epoch {epoch+1}/{num_epochs}, Train Loss: {train_loss:.4f}, Test Loss: {test_loss:.4f}, Accuracy: {

    return accuracy
```

✓ 0.0s Python

Analisis:

Kode tersebut mendefinisikan fungsi untuk melatih dan mengevaluasi model deep learning dengan PyTorch. Fungsi ini mencakup mekanisme pelatihan model menggunakan data dari train_loader, di mana setiap batch diproses dengan menerapkan *forward pass*, menghitung loss dengan fungsi loss (criterion), melakukan *backpropagation*, dan memperbarui bobot model menggunakan optimizer. Setelah melatih model pada setiap epoch, model dievaluasi pada data pengujian dari test_loader dengan menghitung loss dan akurasi. Untuk meningkatkan efisiensi pelatihan, fungsi ini menggunakan scheduler untuk menyesuaikan *learning rate* berdasarkan kinerja model, serta menerapkan *early stopping* untuk menghentikan pelatihan lebih awal jika tidak ada perbaikan pada loss pengujian setelah beberapa epoch berturut-turut. Hasil pelatihan seperti train loss, test loss, dan akurasi dicetak setiap epoch untuk memantau kinerja model. Fungsi ini mengembalikan akurasi akhir setelah proses pelatihan selesai atau ketika *early stopping* dipicu.

```python
# Experiment configurations
hidden_sizes = [16, 32, 64]
poolings = ['max', 'avg']
epochs_list = [5, 50, 100, 250, 350]
optimizers = ['SGD', 'RMSprop', 'Adam']
early_stopper = 10

# Run experiments and save results
results = []
for hidden_size in hidden_sizes:
    for pooling in poolings:
        for optimizer_name in optimizers:
            for num_epochs in epochs_list:
                print("================================================================")
                print(f"\nConfiguration: Hidden Size={hidden_size}, Pooling={pooling}, Optimizer={optimizer_name}, Epochs={num_epochs}")
                model = BiRNN(input_size=X_train.shape[1], hidden_size=hidden_size, num_layers=1, output_size=1, pooling=pooling)
                criterion = nn.BCEWithLogitsLoss()

                if optimizer_name == 'SGD':
                    optimizer = optim.SGD(model.parameters(), lr=0.01)
                elif optimizer_name == 'RMSprop':
                    optimizer = optim.RMSprop(model.parameters(), lr=0.01)
                elif optimizer_name == 'Adam':
                    optimizer = optim.Adam(model.parameters(), lr=0.01)

                scheduler = optim.lr_scheduler.ReduceLROnPlateau(optimizer, mode='min', patience=3, verbose=True)
                accuracy = train_model(model, optimizer, criterion, scheduler, num_epochs, early_stopper, train_loader, test_loader)

                results.append({
                    'Hidden Size': hidden_size,
                    'Pooling': pooling,
                    'Optimizer': optimizer_name,
                    'Epochs': num_epochs,
                    'Accuracy': accuracy
                })

results_df = pd.DataFrame(results)
results_df.to_csv('Experiment_Bidirectional RNN_results.csv', index=False)
```

✓ 136m 53.8s

Output:

```
================================================================

Configuration: Bidirectional RNN Hidden Size=16, Pooling=max, Optimizer=SGD, Epochs=5
Epoch 1/5, Train Loss: 0.4203, Test Loss: 0.3227, Accuracy: 0.8821
Epoch 2/5, Train Loss: 0.2871, Test Loss: 0.2715, Accuracy: 0.8902
Epoch 3/5, Train Loss: 0.2541, Test Loss: 0.2525, Accuracy: 0.8972
Epoch 4/5, Train Loss: 0.2408, Test Loss: 0.2448, Accuracy: 0.8986
Epoch 5/5, Train Loss: 0.2351, Test Loss: 0.2415, Accuracy: 0.9014
================================================================

Configuration: Bidirectional RNN Hidden Size=16, Pooling=max, Optimizer=SGD, Epochs=50
Epoch 1/50, Train Loss: 0.4048, Test Loss: 0.2989, Accuracy: 0.8904
Epoch 2/50, Train Loss: 0.2706, Test Loss: 0.2608, Accuracy: 0.8963
Epoch 3/50, Train Loss: 0.2489, Test Loss: 0.2491, Accuracy: 0.8962
Epoch 4/50, Train Loss: 0.2410, Test Loss: 0.2448, Accuracy: 0.8986
Epoch 5/50, Train Loss: 0.2372, Test Loss: 0.2430, Accuracy: 0.8997
Epoch 6/50, Train Loss: 0.2353, Test Loss: 0.2420, Accuracy: 0.9007
Epoch 7/50, Train Loss: 0.2345, Test Loss: 0.2413, Accuracy: 0.9007
Epoch 8/50, Train Loss: 0.2331, Test Loss: 0.2406, Accuracy: 0.9005
Epoch 9/50, Train Loss: 0.2321, Test Loss: 0.2400, Accuracy: 0.9003
Epoch 10/50, Train Loss: 0.2313, Test Loss: 0.2394, Accuracy: 0.9005
Epoch 11/50, Train Loss: 0.2311, Test Loss: 0.2389, Accuracy: 0.9004
Epoch 12/50, Train Loss: 0.2299, Test Loss: 0.2383, Accuracy: 0.8996
Epoch 13/50, Train Loss: 0.2294, Test Loss: 0.2377, Accuracy: 0.9001
Epoch 14/50, Train Loss: 0.2287, Test Loss: 0.2371, Accuracy: 0.9009
...
Epoch 17/350, Train Loss: 0.1396, Test Loss: 0.2358, Accuracy: 0.8996
Epoch 18/350, Train Loss: 0.1395, Test Loss: 0.2358, Accuracy: 0.8996
Epoch 19/350, Train Loss: 0.1389, Test Loss: 0.2358, Accuracy: 0.8996
Early stopping triggered
```

Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

Analisis:

Kode ini menjalankan serangkaian percobaan untuk menguji performa model *Bidirectional RNN* dengan berbagai pengaturan. Beberapa parameter diuji, seperti jumlah unit tersembunyi (*hidden size*), jenis metode pooling (max atau average), tipe optimizer (SGD, RMSprop, atau Adam), dan jumlah epoch pelatihan. Untuk setiap kombinasi parameter, model dilatih menggunakan data pelatihan dan dievaluasi pada data pengujian. Selain itu, digunakan scheduler untuk menyesuaikan *learning rate* berdasarkan performa model, serta mekanisme *early stopping* untuk menghentikan pelatihan jika tidak ada perbaikan pada loss validasi setelah beberapa epoch. Akurasi dari setiap pengaturan dicatat dan disimpan dalam file CSV agar hasilnya bisa dianalisis lebih lanjut. Dengan cara ini, kita dapat membandingkan performa model dengan berbagai kombinasi parameter dan menemukan pengaturan terbaik.

```python
def visualize_results(results_df):
    plt.figure(figsize=(12, 6))
    sns.lineplot(data=results_df, x='Epochs', y='Accuracy', hue='Optimizer', style='Pooling', markers=True, dashes=
    plt.title('Accuracy vs Epochs for Different Configurations')
    plt.ylabel('Accuracy')
    plt.xlabel('Epochs')
    plt.legend(title='Configuration', loc='lower right')
    plt.show()

visualize_results(results_df)
```

✓ 0.3s Python

Output:

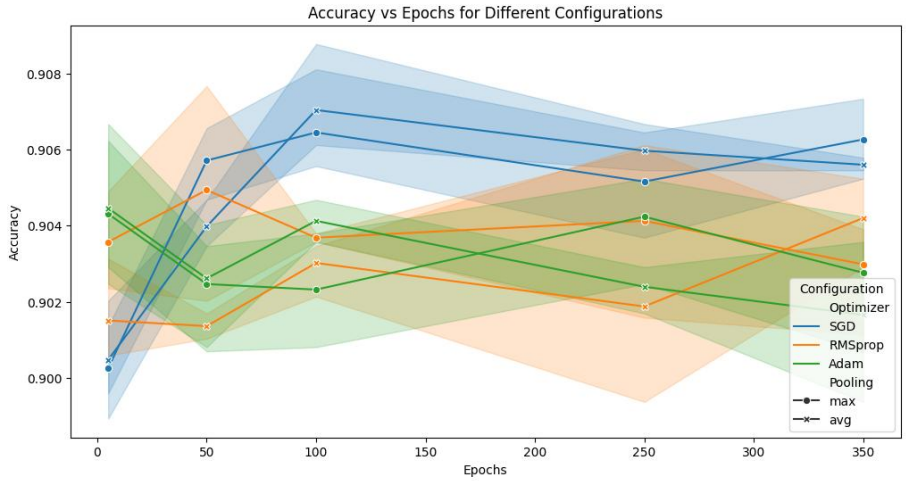

Analisis:

Kode ini digunakan untuk memvisualisasikan hasil percobaan model *Bidirectional RNN* dengan grafik. Fungsi visualize_results mengambil DataFrame hasil percobaan (results_df) dan membuat grafik garis menggunakan Seaborn. Grafik ini menunjukkan hubungan antara jumlah epoch pelatihan dan akurasi model. Garis-garis dalam grafik dikelompokkan berdasarkan jenis optimizer yang digunakan, dengan gaya garis dan tanda (*markers*) yang berbeda untuk membedakan metode pooling (max atau average). Grafik ini memberikan cara yang jelas untuk membandingkan performa model dengan berbagai konfigurasi, sehingga memudahkan untuk melihat pengaruh jumlah epoch, metode pooling, dan jenis optimizer terhadap akurasi. Hasil akhirnya ditampilkan dalam grafik yang memberikan wawasan visual untuk analisis lebih lanjut.

```python
# Display top 10 as table
from tabulate import tabulate
top_10 = results_df.sort_values(by='Accuracy', ascending=False).head(10)
print("Top 10 Results:")
print(tabulate(top_10, headers='keys', tablefmt='pretty', showindex=False))
```

✓ 0.0s Python

Output:

Top 10 Results:

Model Type	Hidden Size	Pooling	Optimizer	Epochs	Accuracy
Bidirectional RNN	64	avg	SGD	100	0.9087692137564968
Bidirectional RNN	16	max	SGD	100	0.9081057171292712
Bidirectional RNN	32	max	RMSprop	50	0.9076633860444543
Bidirectional RNN	64	max	SGD	350	0.9073316377308416
Bidirectional RNN	64	avg	SGD	250	0.906668141103616
Bidirectional RNN	64	avg	Adam	5	0.906668141103616
Bidirectional RNN	32	max	SGD	50	0.9065575583324118
Bidirectional RNN	64	max	SGD	250	0.9064469755612076
Bidirectional RNN	16	max	SGD	350	0.9062258100187991
Bidirectional RNN	32	max	Adam	5	0.9062258100187991

Analisis:

Kode tersebut menampilkan 10 hasil terbaik dari eksperimen model *Bidirectional RNN* berdasarkan akurasi tertinggi. Pertama, DataFrame results_df diurutkan berdasarkan kolom Accuracy dalam urutan menurun menggunakan sort_values. Sepuluh baris teratas dari hasil yang diurutkan diambil dengan head(10). Untuk menyajikan hasil secara rapi, digunakan pustaka tabulate, yang membuat tabel dengan format yang lebih mudah dibaca. Tabel menampilkan konfigurasi model seperti ukuran unit tersembunyi (*Hidden Size*), metode pooling (*Pooling*), jenis optimizer, jumlah epoch pelatihan, dan akurasi yang dicapai. Tabel ini memberikan gambaran jelas tentang kombinasi parameter yang menghasilkan performa terbaik dalam eksperimen.