Nama : Az – Zahra Chikal E

NIM : 1103213039

Kelas : TK-45-05

TUGAS WEEK 14 MARKOV

```
import numpy as np
import pandas as pd
import torch
import torch.nn as nn
import torch.optim as optim
from torch.utils.data import DataLoader, Dataset
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from hmmlearn import hmm
from tqdm import tqdm    Import "tqdm" could not be resolved from source
import matplotlib.pyplot as plt
import seaborn as sns
```

✓ 1.5s Python

```
# Load and preprocess data
data = pd.read_csv('bank-full.csv', delimiter=';')
data.head()
```

✓ 0.0s Python

Output:

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
0	58	management	married	tertiary	no	2143	yes	no	unknown	5	may	261	1	-1	0	unknown	no
1	44	technician	single	secondary	no	29	yes	no	unknown	5	may	151	1	-1	0	unknown	no
2	33	entrepreneur	married	secondary	no	2	yes	yes	unknown	5	may	76	1	-1	0	unknown	no
3	47	blue-collar	married	unknown	no	1506	yes	no	unknown	5	may	92	1	-1	0	unknown	no
4	33	unknown	single	unknown	no	1	no	no	unknown	5	may	198	1	-1	0	unknown	no

Analisis:

Kode diatas digunakan untuk membuat model machine learning menggunakan PyTorch. Data yang digunakan yaitu bernama `bank-full.csv`, yang berisi informasi tentang pelanggan bank. Data ini dimuat ke dalam program menggunakan Pandas dengan pemisah `;` karena format filenya menggunakan titik koma untuk memisahkan kolom. Untuk memahami isi dan struktur data, ditampilkan beberapa baris pertama dengan `data.head()`. Selanjutnya, data ini akan diproses dan dianalisis menggunakan alat bantu seperti NumPy, Scikit-learn, serta divisualisasikan menggunakan Matplotlib dan Seaborn sebelum digunakan untuk melatih model.

```
data.info()
```

✓ 0.0s Python

```
data.describe()
```

✓ 0.0s Python

Output:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 45211 entries, 0 to 45210
Data columns (total 17 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   age        45211 non-null  int64
 1   job        45211 non-null  object
 2   marital    45211 non-null  object
 3   education  45211 non-null  object
 4   default    45211 non-null  object
 5   balance    45211 non-null  int64
 6   housing    45211 non-null  object
 7   loan       45211 non-null  object
 8   contact    45211 non-null  object
 9   day        45211 non-null  int64
 10  month      45211 non-null  object
 11  duration   45211 non-null  int64
 12  campaign   45211 non-null  int64
 13  pdays      45211 non-null  int64
 14  previous   45211 non-null  int64
 15  poutcome   45211 non-null  object
 16  y          45211 non-null  object
dtypes: int64(7), object(10)
memory usage: 5.9+ MB
```

	age	balance	day	duration	campaign	pdays	previous
count	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000
mean	40.936210	1362.272058	15.806419	258.163080	2.763841	40.197828	0.580323
std	10.618762	3044.765829	8.322476	257.527812	3.098021	100.128746	2.303441
min	18.000000	-8019.000000	1.000000	0.000000	1.000000	-1.000000	0.000000
25%	33.000000	72.000000	8.000000	103.000000	1.000000	-1.000000	0.000000
50%	39.000000	448.000000	16.000000	180.000000	2.000000	-1.000000	0.000000
75%	48.000000	1428.000000	21.000000	319.000000	3.000000	-1.000000	0.000000
max	95.000000	102127.000000	31.000000	4918.000000	63.000000	871.000000	275.000000

Analisis:

Kode tersebut digunakan untuk mengetahui informasi terkait dataet. Dari code tersebut dapat kita tahui bahwa terdapat 16 kolom dengan jumlah data yaitu 45211. untuk datatype terdapat 2 yaitu int dan object. Fungsi `df.describe()` digunakan untuk memberikan ringkasan statistik dasar dari data numerik dalam sebuah DataFrame. Hasilnya mencakup informasi seperti jumlah data (count), rata-rata (mean), standar deviasi (std), nilai minimum (min), kuartil (25%, 50%, 75%), dan nilai maksimum (max) untuk setiap kolom numerik. Dengan menggunakan fungsi ini, kita dapat dengan cepat memahami karakteristik umum data, seperti distribusi nilai, rentang data, dan keberadaan kemungkinan nilai ekstrem.

```python
# Distribution of target variable 'y'
sns.countplot(data['y'])
plt.title('Distribution of Target Variable (y)')
plt.xlabel('y (Target)')
plt.ylabel('Count')
plt.show()
```

✓ 0.1s Python

Output:

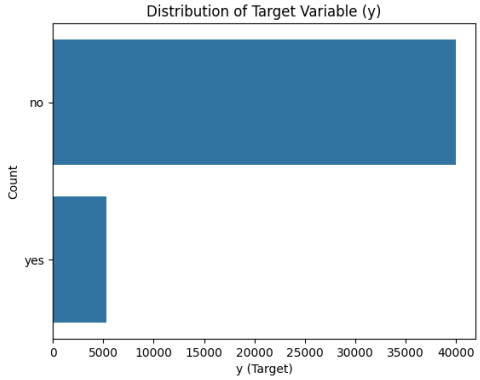

Analisis:
Grafik countplot menunjukkan distribusi data pada variabel target y. Sumbu horizontal menampilkan kategori dalam variabel y, sementara sumbu vertikal menunjukkan jumlah data untuk setiap kategori tersebut. Dari grafik ini, kita bisa melihat apakah data dalam variabel target seimbang atau tidak. Jika salah satu kategori memiliki jumlah data yang jauh lebih banyak dibandingkan kategori lain, itu berarti data tidak seimbang, dan hal ini perlu diperhatikan saat membuat model prediksi.

```python
# Distribution of numerical variables
numerical_cols = ['age', 'balance', 'day', 'duration', 'campaign', 'pdays', 'previous']
data[numerical_cols].hist(figsize=(15, 10), bins=20, edgecolor='black')
plt.suptitle('Distributions of Numerical Features')
plt.show()
```

✓ 0.4s Python

Output:

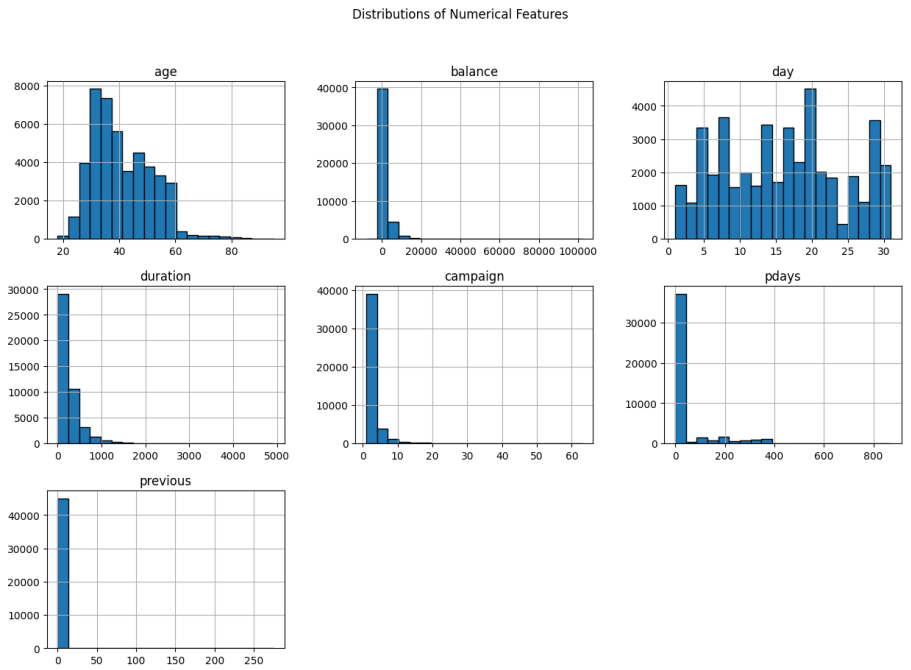

Analisis:
Histogram menunjukkan bagaimana data tersebar untuk variabel numerik seperti age, balance, day, duration, campaign, pdays, dan previous. Setiap variabel memiliki grafiknya sendiri yang menampilkan nilai-nilai data di sumbu horizontal dan jumlah kemunculannya di sumbu vertikal. Dari grafik ini, kita bisa melihat apakah distribusi data merata, condong ke satu sisi, atau memiliki nilai ekstrem (outlier). Tampilan ini membantu kita memahami pola data dan menentukan apakah ada perlakuan khusus yang perlu dilakukan, seperti normalisasi atau transformasi, sebelum digunakan dalam analisis lebih lanjut atau pembuatan model.

```python
# Categorical variables analysis
categorical_cols = ['job', 'marital', 'education', 'default', 'housing', 'loan', 'contact', 'month', 'poutcome']

for col in categorical_cols:
    plt.figure(figsize=(10, 5))
    sns.countplot(data[col], order=data[col].value_counts().index)
    plt.title(f'Distribution of {col}')
    plt.xticks(rotation=45)
    plt.ylabel('Count')
    plt.show()
```

✓ 0.9s Python

Output:

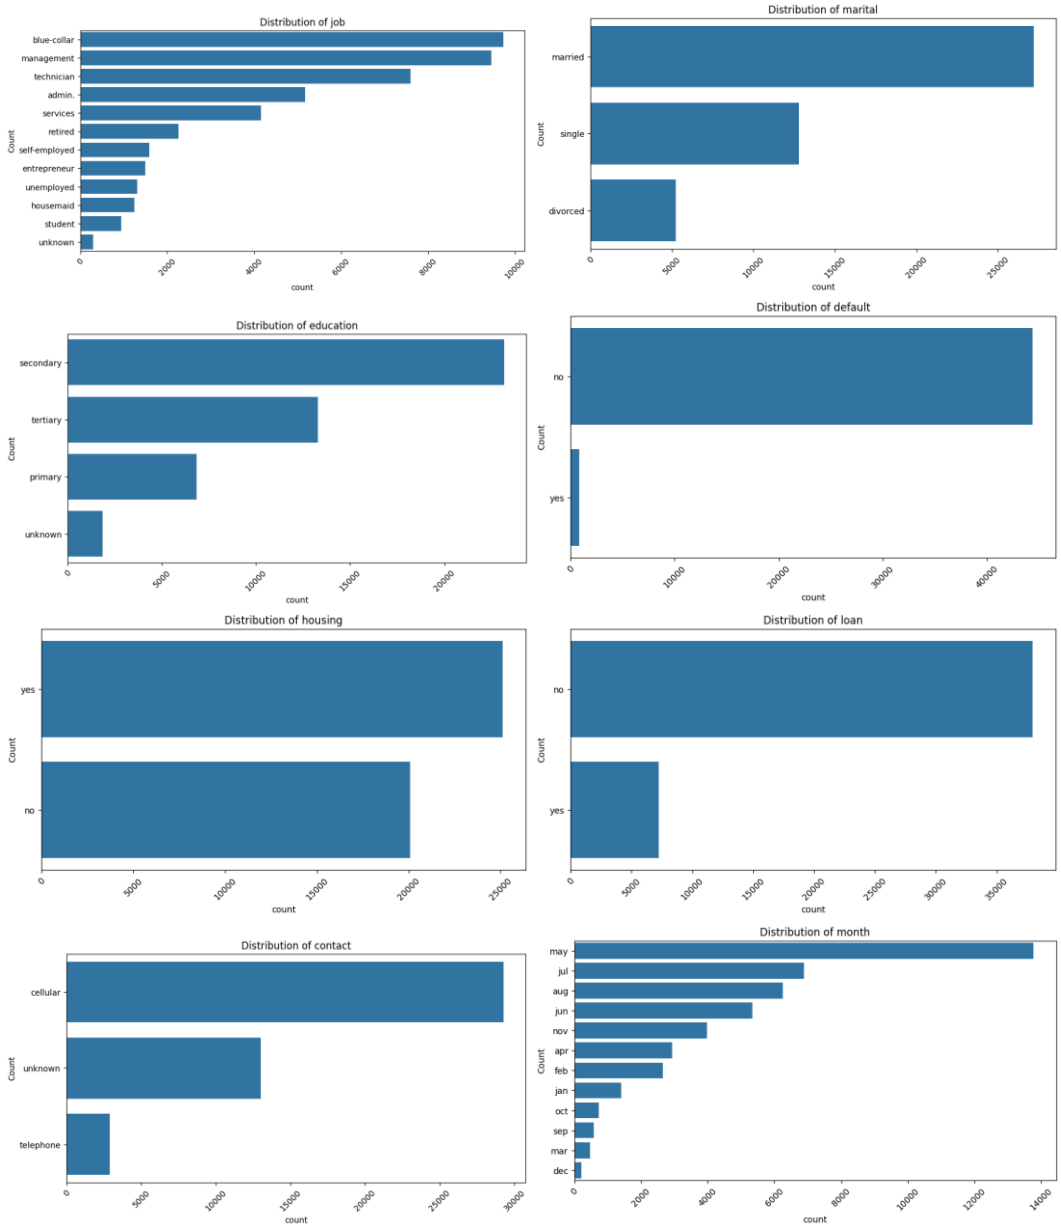

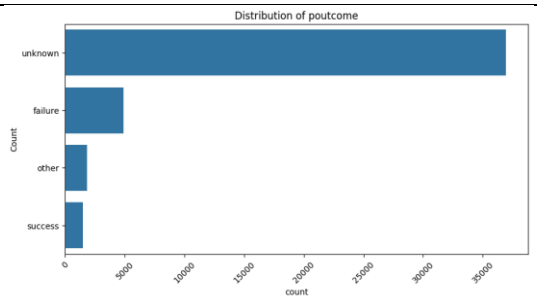

Analisis:

Grafik ini menunjukkan bagaimana data tersebar untuk variabel kategori seperti job, marital, education, default, housing, loan, contact, month, dan poutcome. Setiap variabel memiliki grafik batang (countplot) yang memperlihatkan jumlah data di setiap kategori. Sumbu horizontal menampilkan kategori, sedangkan sumbu vertikal menunjukkan jumlah data untuk masing-masing kategori. Kategori dalam grafik diurutkan dari yang paling banyak hingga paling sedikit, sehingga memudahkan kita untuk melihat kategori mana yang dominan. Label kategori dibuat miring (rotasi 45 derajat) agar tetap terbaca dengan jelas, terutama jika nama kategorinya panjang. Analisis ini penting untuk memahami pola data pada variabel kategori, seperti kategori yang sering muncul atau jarang, yang mungkin memengaruhi analisis lebih lanjut atau model yang akan dibuat.

```python
# Correlation heatmap for numerical features
correlation_matrix = data[numerical_cols].corr()
plt.figure(figsize=(10, 8))
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt='.2f')
plt.title('Correlation Heatmap of Numerical Features')
plt.show()
```

0.1s Python

Output:

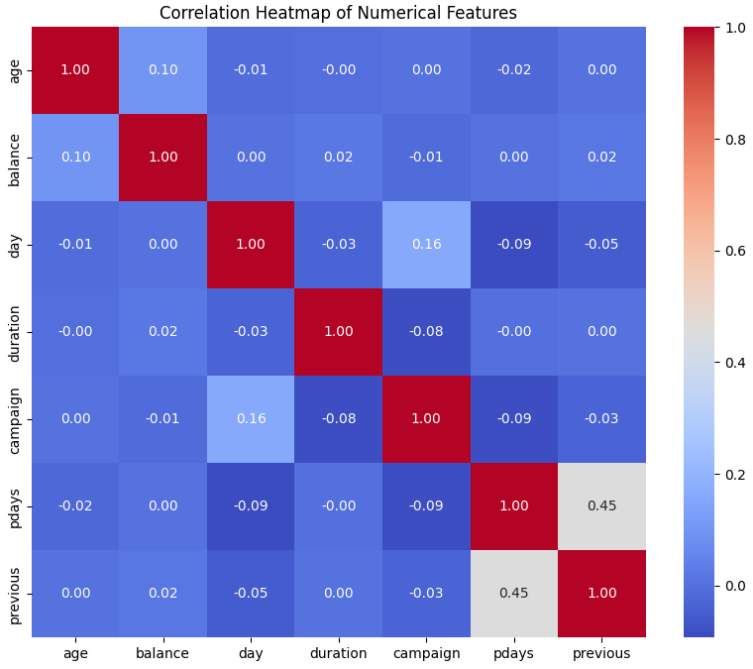

Analisis:

Heatmap ini menunjukkan hubungan antara variabel-variabel numerik dalam dataset, seperti age, balance, day, duration, campaign, pdays, dan previous. Setiap kotak dalam heatmap menggambarkan tingkat hubungan (korelasi) antara dua variabel, dengan nilai berkisar dari -1 hingga 1. Jika nilainya mendekati 1, berarti ada hubungan positif yang kuat, artinya jika satu variabel naik, variabel lain juga cenderung naik. Jika nilainya mendekati -1, berarti ada hubungan negatif yang kuat, artinya jika satu variabel naik, variabel lain cenderung turun. Nilai mendekati 0 menunjukkan tidak ada hubungan linear yang signifikan. Warna pada heatmap membantu membedakan kekuatan hubungan. warna merah menunjukkan hubungan negatif yang kuat, sementara warna biru menunjukkan hubungan positif yang kuat.

```python
# Boxplot to check outliers in numerical features
plt.figure(figsize=(15, 10))
for i, col in enumerate(numerical_cols, 1):
    plt.subplot(3, 3, i)
    sns.boxplot(data[col])
    plt.title(f'Boxplot of {col}')
plt.tight_layout()
plt.show()
```

✓ 0.6s Python

Output:

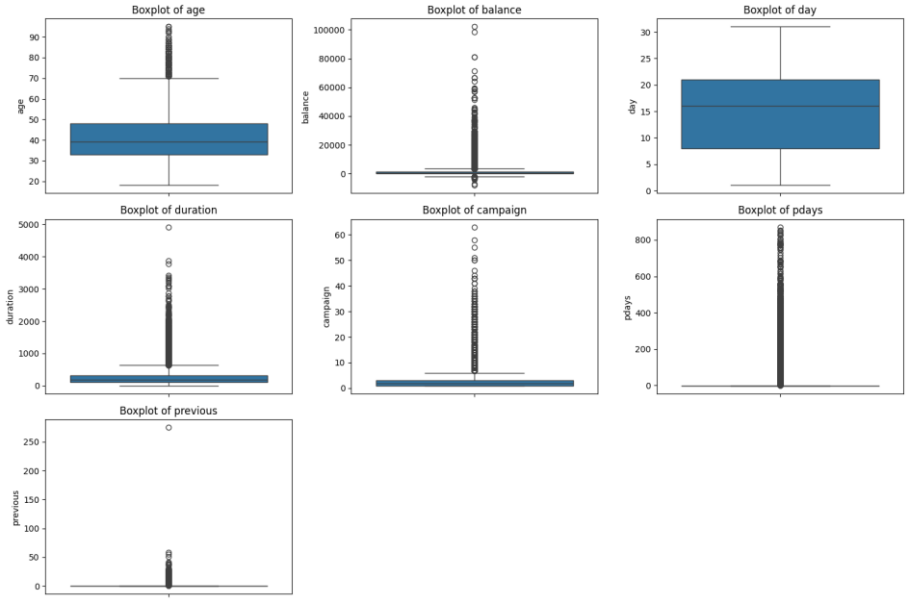

Analisis:

Boxplot digunakan untuk melihat apakah ada outlier (data ekstrem) pada variabel numerik seperti age, balance, day, duration, campaign, pdays, dan previous. Boxplot menunjukkan ringkasan distribusi data, termasuk nilai terkecil, kuartil pertama (Q1), median, kuartil ketiga (Q3), dan nilai terbesar. Data yang dianggap outlier biasanya ditampilkan sebagai titik-titik di luar garis "whiskers".

Setiap variabel memiliki boxplot sendiri yang ditampilkan dalam grafik, sehingga kita bisa melihat pola outlier secara lebih jelas untuk masing-masing variabel. Jika banyak outlier ditemukan, langkah-langkah seperti menghapus, mengubah, atau menangani data ekstrem tersebut mungkin perlu dilakukan. Selain itu, boxplot juga membantu kita memahami pola

distribusi data, misalnya apakah data cenderung simetris atau memiliki kemiringan ke satu sisi.

```python
# Preprocessing
def preprocess_data(data):
    X = data.drop('y', axis=1)
    X = pd.get_dummies(X)
    y = data['y'].apply(lambda x: 1 if x == 'yes' else 0)

    scaler = StandardScaler()
    X = scaler.fit_transform(X)

    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
    return X_train, X_test, y_train, y_test

X_train, X_test, y_train, y_test = preprocess_data(data)

# Dataset class
class CustomDataset(Dataset):
    def __init__(self, X, y):
        self.X = torch.tensor(X, dtype=torch.float32)
        self.y = torch.tensor(y.values, dtype=torch.float32)

    def __len__(self):
        return len(self.y)

    def __getitem__(self, idx):
        return self.X[idx], self.y[idx]

train_dataset = CustomDataset(X_train, y_train)
test_dataset = CustomDataset(X_test, y_test)

train_loader = DataLoader(train_dataset, batch_size=64, shuffle=True)
test_loader = DataLoader(test_dataset, batch_size=64, shuffle=False)
```

✓ 0.1s Python

Analisis:

Proses ini mencakup langkah-langkah untuk menyiapkan data agar bisa digunakan dalam pelatihan model. Pertama, data dipisahkan menjadi fitur (X) dan target (y). Variabel target y diubah menjadi format biner, di mana yes menjadi 1 dan no menjadi 0. Selanjutnya, fitur kategori dalam X diubah menjadi angka melalui proses one-hot encoding, sehingga bisa diproses oleh model. Semua fitur kemudian dinormalisasi menggunakan StandardScaler, yang mengatur agar setiap fitur memiliki rata-rata 0 dan standar deviasi 1, sehingga model dapat belajar lebih baik. Data ini kemudian dibagi menjadi data pelatihan (80%) dan pengujian (20%). Setelah data siap, dibuat kelas khusus bernama CustomDataset untuk mengatur data agar kompatibel dengan PyTorch. Kelas ini mengonversi data menjadi tensor PyTorch, dengan metode untuk mendapatkan ukuran dataset (__len__) dan mengakses data berdasarkan indeks (__getitem__). Dataset pelatihan dan pengujian kemudian disiapkan menggunakan kelas ini, dan data loader (DataLoader) digunakan untuk membagi dataset menjadi batch berukuran 64. Batch ini mempermudah proses pelatihan model secara bertahap, dengan data pelatihan diacak untuk meningkatkan kemampuan generalisasi model. Data pengujian tidak diacak untuk menjaga konsistensi evaluasi.

```python
# Define RNN for Markov Model
class RNNMarkovNet(nn.Module):
    def __init__(self, input_size, hidden_size, num_layers, output_size, pooling='max'):
        super(RNNMarkovNet, self).__init__()
        self.rnn = nn.RNN(input_size, hidden_size, num_layers, batch_first=True)
        self.pooling = pooling
        self.fc = nn.Linear(hidden_size, output_size)

    def forward(self, x):
        out, _ = self.rnn(x)
        if self.pooling == 'max':
            out = torch.max(out, dim=1).values
        elif self.pooling == 'avg':
            out = torch.mean(out, dim=1)
        out = self.fc(out)
        return out
```

0.0s Python

Analisis:

Kode tersebut mendefinisikan kelas RNNMarkovNet, sebuah arsitektur model Recurrent Neural Network (RNN) yang dirancang untuk digunakan sebagai representasi model Markov. Kelas ini memiliki layer RNN dengan parameter seperti ukuran input (input_size), ukuran hidden layer (hidden_size), jumlah lapisan (num_layers), dan ukuran output (output_size). Model juga mendukung metode pooling, yaitu max pooling (mengambil nilai maksimum dari output) atau average pooling (mengambil rata-rata dari output) setelah RNN. Hasil dari pooling kemudian diteruskan ke fully connected layer (fc) untuk menghasilkan prediksi akhir. Model ini dirancang untuk menangani data sekuensial dan fleksibel untuk berbagai konfigurasi.

```python
# Train RNN Markov Model
def train_rnn_markov_model(model, optimizer, criterion, scheduler, num_epochs, early_stopper, train_loader, test_l
    best_loss = float('inf')
    patience_counter = 0
    device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
    model = model.to(device)

    for epoch in range(num_epochs):
        model.train()
        train_loss = 0
        for X_batch, y_batch in train_loader:
            X_batch, y_batch = X_batch.to(device), y_batch.to(device)
            optimizer.zero_grad()
            outputs = model(X_batch.unsqueeze(1))
            loss = criterion(outputs.squeeze(), y_batch)
            loss.backward()
            optimizer.step()
            train_loss += loss.item()

        train_loss /= len(train_loader)

        model.eval()
        test_loss = 0
        correct = 0
        total = 0
        with torch.no_grad():
            for X_batch, y_batch in test_loader:
                X_batch, y_batch = X_batch.to(device), y_batch.to(device)
                outputs = model(X_batch.unsqueeze(1))
                loss = criterion(outputs.squeeze(), y_batch)
                test_loss += loss.item()
                predictions = torch.round(torch.sigmoid(outputs.squeeze()))
                correct += (predictions == y_batch).sum().item()
                total += y_batch.size(0)
        test_loss /= len(test_loader)
        accuracy = correct / total

        scheduler.step(test_loss)
```

Analisis:

Fungsi train_model digunakan untuk melatih model dengan data pelatihan dan mengukur kinerjanya pada data pengujian. Proses dimulai dengan menempatkan model di perangkat yang tersedia, seperti GPU (jika ada) atau CPU. Pelatihan dilakukan selama beberapa epoch, di mana setiap epoch terdiri dari dua tahap: pelatihan model dengan data pelatihan dan evaluasi model dengan data pengujian. Pada tahap pelatihan, model memproses data dalam batch dari train_loader. Model menghasilkan output, menghitung loss menggunakan fungsi tertentu (criterion), dan memperbarui parameter model melalui backpropagation dengan bantuan optimizer. Setelah semua batch diproses, rata-rata loss dihitung sebagai ukuran kinerja model selama pelatihan. Tahap evaluasi dilakukan dengan model dalam mode evaluasi, di mana data pengujian diproses tanpa menghitung gradien. Pada tahap ini, loss dan akurasi model dihitung. Akurasi dihitung dengan membandingkan hasil prediksi model dengan label sebenarnya. Fungsi ini juga menggunakan scheduler untuk menyesuaikan laju pembelajaran berdasarkan kinerja pada data pengujian. Early stopping diterapkan untuk menghentikan pelatihan jika performa model tidak meningkat setelah sejumlah epoch tertentu, menghindari pemborosan waktu dan sumber daya. Hasil dari setiap epoch, seperti loss dan akurasi, dicetak untuk memantau kinerja model. Jika model mencapai performa terbaiknya, hasil akhir berupa akurasi pada data pengujian dikembalikan. Fungsi ini memastikan model dilatih dengan efisien dan berhenti tepat waktu saat tidak ada peningkatan signifikan.

```python
# Experiment with RNN Markov Model
hidden_sizes = [32, 64]
poolings = ['max', 'avg']
epochs_list = [5, 50, 100, 250, 350]
optimizers = ['SGD', 'RMSprop', 'Adam']
early_stopper = 10

results_rnn_markov = []
for hidden_size in hidden_sizes:
    for pooling in poolings:
        for optimizer_name in optimizers:
            for num_epochs in epochs_list:
                print("==========================================================")
                print(f"\nConfiguration: RNN Markov Hidden Size={hidden_size}, Pooling={pooling}, Optimizer={optim
                model = RNNMarkovNet(input_size=X_train.shape[1], hidden_size=hidden_size, num_layers=1, output_si
                criterion = nn.BCEWithLogitsLoss()

                if optimizer_name == 'SGD':
                    optimizer = optim.SGD(model.parameters(), lr=0.01)
                elif optimizer_name == 'RMSprop':
                    optimizer = optim.RMSprop(model.parameters(), lr=0.01)
                elif optimizer_name == 'Adam':
                    optimizer = optim.Adam(model.parameters(), lr=0.01)

                scheduler = optim.lr_scheduler.ReduceLROnPlateau(optimizer, mode='min', patience=3, verbose=True)
                accuracy = train_rnn_markov_model(model, optimizer, criterion, scheduler, num_epochs, early_stoppe

                results_rnn_markov.append({
                    'Model': 'RNN MarkovNet',
                    'Hidden Size': hidden_size,
                    'Pooling': pooling,
                    'Optimizer': optimizer_name,
                    'Epochs': num_epochs,
                    'Accuracy': accuracy
                })

results_rnn_markov_df = pd.DataFrame(results_rnn_markov)
results_rnn_markov_df.to_csv('rnn_markov_experiment_results.csv', index=False)
```

✓ 105m 10.0s Python

Output:

```
==========================================================

Configuration: RNN Markov Hidden Size=32, Pooling=max, Optimizer=SGD, Epochs=5
Epoch 1/5, Train Loss: 0.4022, Test Loss: 0.3072, Accuracy: 0.8826
Epoch 2/5, Train Loss: 0.2711, Test Loss: 0.2587, Accuracy: 0.8944
Epoch 3/5, Train Loss: 0.2443, Test Loss: 0.2459, Accuracy: 0.8986
Epoch 4/5, Train Loss: 0.2366, Test Loss: 0.2419, Accuracy: 0.8995
Epoch 5/5, Train Loss: 0.2337, Test Loss: 0.2401, Accuracy: 0.9004
==========================================================

Configuration: RNN Markov Hidden Size=32, Pooling=max, Optimizer=SGD, Epochs=50
Epoch 1/50, Train Loss: 0.3959, Test Loss: 0.2936, Accuracy: 0.8882
Epoch 2/50, Train Loss: 0.2625, Test Loss: 0.2561, Accuracy: 0.8953
Epoch 3/50, Train Loss: 0.2422, Test Loss: 0.2466, Accuracy: 0.8980
Epoch 4/50, Train Loss: 0.2363, Test Loss: 0.2435, Accuracy: 0.8990
Epoch 5/50, Train Loss: 0.2341, Test Loss: 0.2422, Accuracy: 0.9000
Epoch 6/50, Train Loss: 0.2326, Test Loss: 0.2411, Accuracy: 0.8997
Epoch 7/50, Train Loss: 0.2329, Test Loss: 0.2404, Accuracy: 0.9004
Epoch 8/50, Train Loss: 0.2311, Test Loss: 0.2397, Accuracy: 0.8999
Epoch 9/50, Train Loss: 0.2304, Test Loss: 0.2389, Accuracy: 0.9004
Epoch 10/50, Train Loss: 0.2293, Test Loss: 0.2383, Accuracy: 0.9005
Epoch 11/50, Train Loss: 0.2286, Test Loss: 0.2375, Accuracy: 0.9004
Epoch 12/50, Train Loss: 0.2280, Test Loss: 0.2368, Accuracy: 0.9010
Epoch 13/50, Train Loss: 0.2269, Test Loss: 0.2362, Accuracy: 0.9005
Epoch 14/50, Train Loss: 0.2262, Test Loss: 0.2354, Accuracy: 0.9014
...
Epoch 12/350, Train Loss: 0.1618, Test Loss: 0.2183, Accuracy: 0.9066
Epoch 13/350, Train Loss: 0.1572, Test Loss: 0.2185, Accuracy: 0.9067
Epoch 14/350, Train Loss: 0.1571, Test Loss: 0.2188, Accuracy: 0.9063
Early stopping triggered
```

Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

Analisis:

Kode ini menjalankan eksperimen untuk melatih model RNN MarkovNet dengan berbagai konfigurasi parameter dan menyimpan hasilnya dalam file CSV. Eksperimen ini menguji

beberapa kombinasi parameter, seperti ukuran lapisan tersembunyi (hidden_size), metode pooling (max atau average), jenis optimizer (SGD, RMSprop, atau Adam), dan jumlah epoch (misalnya 5, 50, hingga 350). Tujuannya adalah menemukan konfigurasi terbaik yang memberikan akurasi tertinggi pada data pengujian. Untuk setiap kombinasi parameter, model RNN MarkovNet dibuat dengan satu lapisan RNN, dan metode pooling digunakan untuk merangkum output dari lapisan RNN. Fungsi loss yang digunakan adalah BCEWithLogitsLoss untuk menangani masalah klasifikasi biner. Optimizer disesuaikan berdasarkan parameter yang dipilih, dan scheduler digunakan untuk menyesuaikan laju pembelajaran jika performa model stagnan. Early stopping diterapkan untuk menghentikan pelatihan lebih awal jika tidak ada peningkatan performa selama 10 epoch berturut-turut. Setelah setiap eksperimen selesai, akurasi model dicatat bersama dengan konfigurasi yang digunakan. Semua hasil disimpan dalam DataFrame pandas dan kemudian diekspor ke file CSV bernama rnn_markov_experiment_results.csv. File ini memudahkan analisis lebih lanjut untuk menentukan kombinasi parameter terbaik bagi model.

```python
# Prepare sequences for HMM
data['job'] = data['job'].astype('category').cat.codes
sequence = data['job'].values
train_seq, test_seq = train_test_split(sequence, test_size=0.2, random_state=42)

# Train Hidden Markov Model
def train_hmm(sequence, n_components):
    hmm_model = hmm.MultinomialHMM(n_components=n_components, n_iter=100, random_state=42)
    sequence = np.array(sequence).reshape(-1, 1)
    hmm_model.fit(sequence)
    return hmm_model

hmm_hidden_states = [2, 3, 5, 7]
hmm_results = []

for n_components in hmm_hidden_states:
    hmm_model = train_hmm(train_seq, n_components=n_components)
    log_likelihood = hmm_model.score(np.array(test_seq).reshape(-1, 1))
    hmm_results.append({
        'Model': 'Hidden Markov Model',
        'Hidden States': n_components,
        'Log Likelihood': log_likelihood
    })

hmm_results_df = pd.DataFrame(hmm_results)
hmm_results_df.to_csv('hmm_experiment_results.csv', index=False)
```

✓ 0.7s Python

Output:

```
MultinomialHMM has undergone major changes. The previous version was implementing a CategoricalHMM (a special case of
https://github.com/hmmlearn/hmmlearn/issues/335
https://github.com/hmmlearn/hmmlearn/issues/340
MultinomialHMM has undergone major changes. The previous version was implementing a CategoricalHMM (a special case of
https://github.com/hmmlearn/hmmlearn/issues/335
https://github.com/hmmlearn/hmmlearn/issues/340
MultinomialHMM has undergone major changes. The previous version was implementing a CategoricalHMM (a special case of
https://github.com/hmmlearn/hmmlearn/issues/335
https://github.com/hmmlearn/hmmlearn/issues/340
MultinomialHMM has undergone major changes. The previous version was implementing a CategoricalHMM (a special case of
https://github.com/hmmlearn/hmmlearn/issues/335
https://github.com/hmmlearn/hmmlearn/issues/340
```

Analisis:

Kode ini mempersiapkan dan melatih model Hidden Markov Model (HMM) menggunakan data kategori pada kolom job. Data dikonversi menjadi kode kategori dan dibagi menjadi data pelatihan (train_seq) dan pengujian (test_seq). Fungsi train_hmm digunakan untuk melatih model HMM dengan jumlah state tersembunyi tertentu (n_components). Model dilatih untuk berbagai nilai n_components (2, 3, 5, 7). Setelah model dilatih, skor log likelihood dihitung menggunakan data pengujian untuk mengevaluasi kualitas model. Hasil

dari eksperimen ini, termasuk jumlah state tersembunyi dan log likelihood, disimpan dalam DataFrame dan diekspor ke file CSV untuk analisis lebih lanjut.

```python
# Visualize Results
plt.figure(figsize=(12, 6))
sns.boxplot(data=results_rnn_markov_df, x='Optimizer', y='Accuracy', hue='Pooling')
plt.title('Accuracy Distribution by Optimizer and Pooling Method (RNN MarkovNet)')
plt.ylabel('Accuracy')
plt.xlabel('Optimizer')
plt.legend(title='Pooling', loc='lower right')
plt.savefig('rnn_markov_accuracy_distribution.png')
plt.show()
```

✓ 0.2s Python

Output:

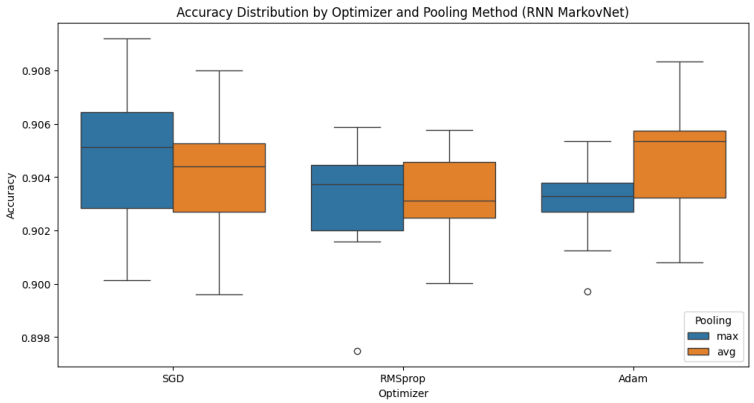

Analisis:

Fungsi ini menggabungkan hasil eksperimen model RNN MarkovNet, lalu membuat grafik boxplot untuk membandingkan distribusi akurasi berdasarkan jenis model dan metode pooling (max atau average). Grafik menunjukkan variasi akurasi untuk setiap kombinasi model dan pooling, membantu memahami performa terbaik. Hasil grafik disimpan sebagai file accuracy_distribution.png dan ditampilkan untuk analisis lebih lanjut.

```python
# Plot Accuracy vs Epochs
plt.figure(figsize=(12, 6))
sns.lineplot(data=results_rnn_markov_df, x='Epochs', y='Accuracy', hue='Optimizer', style='Pooling', markers=True,
plt.title('Accuracy vs Epochs for Different Configurations')
plt.ylabel('Accuracy')
plt.xlabel('Epochs')
plt.legend(title='Configuration', loc='lower right')
plt.savefig('accuracy_vs_epochs.png')
plt.show()
```

✓ 0.4s Python

Output:

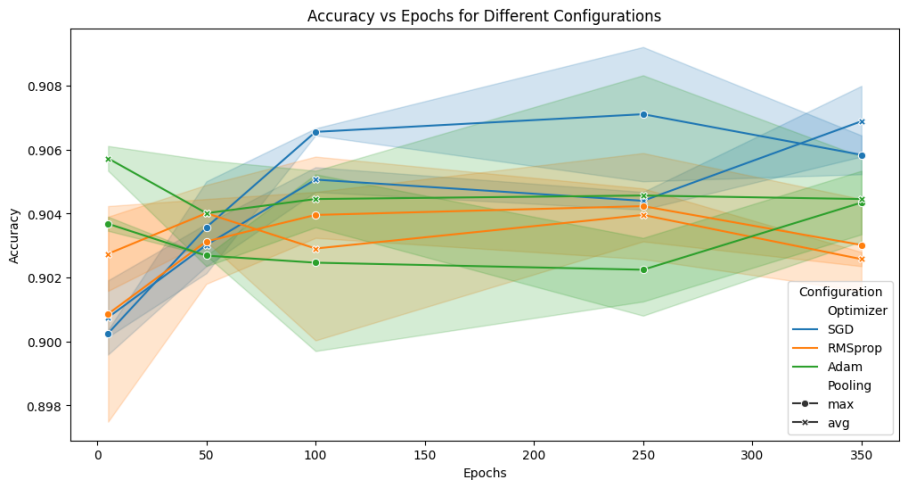

Analisis:

Kode ini digunakan untuk memvisualisasikan hasil percobaan model *RNN* MarkovNet dengan grafik. Fungsi visualize_results mengambil DataFrame hasil percobaan (results_df) dan membuat grafik garis menggunakan Seaborn. Grafik ini menunjukkan hubungan antara jumlah epoch pelatihan dan akurasi model. Garis-garis dalam grafik dikelompokkan berdasarkan jenis optimizer yang digunakan, dengan gaya garis dan tanda (*markers*) yang berbeda untuk membedakan metode pooling (max atau average). Grafik ini memberikan cara yang jelas untuk membandingkan performa model dengan berbagai konfigurasi, sehingga memudahkan untuk melihat pengaruh jumlah epoch, metode pooling, dan jenis optimizer terhadap akurasi. Hasil akhirnya ditampilkan dalam grafik yang memberikan wawasan visual untuk analisis lebih lanjut.

```python
# Combine Results and Top 10 Configurations
combined_results = results_rnn_markov_df

top_10 = combined_results.sort_values(by='Accuracy', ascending=False).head(10)
print("Top 10 Configurations by Accuracy:")

# Save as table
from tabulate import tabulate
print(tabulate(top_10, headers='keys', tablefmt='pretty', showindex=False))
```

0.0s Python

Output:

```
Top 10 Configurations by Accuracy:
+---------------+-------------+---------+-----------+--------+--------------------+
|     Model     | Hidden Size | Pooling | Optimizer | Epochs |      Accuracy      |
+---------------+-------------+---------+-----------+--------+--------------------+
| RNN MarkovNet |     64      |   max   |    SGD    |  250   | 0.9092115448413136 |
| RNN MarkovNet |     32      |   avg   |   Adam    |  250   | 0.9083268826716796 |
| RNN MarkovNet |     64      |   avg   |    SGD    |  350   | 0.907995134358067  |
| RNN MarkovNet |     32      |   max   |    SGD    |  100   | 0.906668141103616  |
| RNN MarkovNet |     64      |   max   |    SGD    |  350   | 0.9064469755612076 |
| RNN MarkovNet |     64      |   max   |    SGD    |  100   | 0.9064469755612076 |
| RNN MarkovNet |     64      |   avg   |   Adam    |   5    | 0.9061152272475947 |
| RNN MarkovNet |     32      |   max   |  RMSprop  |  250   | 0.9058940617051864 |
| RNN MarkovNet |     32      |   avg   |    SGD    |  350   | 0.905783478933982  |
| RNN MarkovNet |     64      |   avg   |   Adam    |  350   | 0.905783478933982  |
+---------------+-------------+---------+-----------+--------+--------------------+
```

Analisis:

Kode ini menampilkan 10 konfigurasi model dengan akurasi tertinggi dari hasil eksperimen model RNN Markovnet. Data diurutkan berdasarkan akurasi secara menurun, lalu 10 konfigurasi terbaik ditampilkan dalam bentuk tabel yang rapi menggunakan library tabulate. Tabel ini memuat informasi seperti jenis model, ukuran lapisan tersembunyi, metode pooling, optimizer, jumlah epoch, dan akurasi yang dicapai. Hasil ini membantu melihat konfigurasi yang paling optimal untuk performa terbaik.